

Lora简介

$$W_{new} = W_{old} + \Delta W$$
$$W_{new} = W_{old} + \frac{\alpha}{r} * (A \times B)$$
$$W_{new}, W_{old} \in \mathbb{R}^{d \times k}, A \in \mathbb{R}^{d \times r}, B \in \mathbb{R}^{r \times k}$$

Lora加载

- 加载lora权重
 - `lora = comfy.utils.load_torch_file(lora_path, safe_load=True)`
- 获取key_map: 根据当前的unet网络, 计算可能的lora的key
 - `key_map = comfy.lora.model_lora_keys_unet(model.model, key_map)`
 - key: lora中的key; value: unet中的key; 一个value可能对应多个key (不同的lora框架有不同的key)
- 匹配得到lora参数: 根据key_map和lora权重匹配, 得到矩阵A、矩阵B、alpha值
 - `loaded = comfy.lora.load_lora(lora, key_map)`
- 更新ModelPatcher: clone一个新的patcher出来, 然后把lora的权重放到patch中, 然后更新uuid
 - `new_modelpatcher = model.clone()`
 - `k = new_modelpatcher.add_patches(loaded, strength_model)`

权重更新

lora加载只会记录lora的信息, 并没有直接更新模型的权重。而是再后续才会计算模型权重:

- KSampler prepare的时候会把unet加载到gpu; clip encode的时候会把clip加载到gpu。这个时候会调用load, 然后调用patch_weight_to_device, 然后调用calculate_weight, 把delta weight算出来