

ModelPatcher

- 对BaseModel (nn.Module) 进行封装
- 记录权重需要用到的补丁，后续真正加载的时候，会通过补丁的信息计算补丁后的实际权重。
- ModelPatcher的备份 (clone) 共用同一个nn.Module，但是补丁的内容不同。

LoadedModel

- 对ModelPatcher的封装
- model_management.py里面的操作单元，即列表current_loaded_models中的元素
 - current_loaded_models记录已经加载到gpu中的模型

load_models_gpu

- 把模型加载到gpu中。
- 把共用BaseModel的LoadedModel进行unload
- 对于同一个BaseModel，只保留最新最全的LoadedModel

功能：

- 定义各种情况应该使用什么硬件 以及 什么计算精度
 - 包括：初始化时 (init)、计算时 (_device)、计算后 (offload_device)
- 定义了一些工具方法，比如模型要占用的显存、内存大小等。
- 让模型在不同硬件之间迁移，主要是gpu和非gpu的迁移

